



```
In [1]: import pandas as pd
import numpy as np
df = df = pd.read_csv('path', encoding = 'cp1251', sep = ';', decimal = ',')
```

```
In [2]: # Первые строки
df.head()
```

```
Out[2]:
```

	new_id	Месяц	Трафик	Средний чек	Дата открытия, категориальный	Торговая площадь, категориальный	Нас
0	0	10	59662	823.060390	Средний по возрасту	Средний	К
1	0	5	56674	859.361975	Средний по возрасту	Средний	К
2	0	1	51488	763.937766	Средний по возрасту	Средний	К
3	0	6	56693	836.362309	Средний по возрасту	Средний	К
4	0	7	58128	845.257709	Средний по возрасту	Средний	К

```
In [3]: df.shape
```

```
Out[3]: (256723, 18)
```

```
In [4]: df.dtypes
```

```
Out[4]: new_id          int64
Месяц          int64
Трафик          int64
Средний чек      float64
Дата открытия, категориальный  object
Торговая площадь, категориальный  object
Населенный пункт  object
Регион          object
Численность населения  int64
Количество домохозяйств  int64
Трафик пеший, в час  float64
Трафик авто, в час  float64
Маркетплейсы, доставки, постаматы (100 м)  int64
Медицинские уч. и аптеки (300 м)  int64
Школы (300 м)  int64
Остановки (300 м)  int64
Продуктовые магазины (500 м)  int64
Пятерочки (500 м)  int64
dtype: object
```

```
In [5]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 256723 entries, 0 to 256722
Data columns (total 18 columns):
#   Column                                                                 Non-Null Count  Dtype
---  -
0   new_id                                                                256723 non-null int64
1   Месяц                                                                256723 non-null int64
2   Трафик                                                                256723 non-null int64
3   Средний чек                                                            256723 non-null float64
4   Дата открытия, категориальный                                         256723 non-null object
5   Торговая площадь, категориальный                                       256723 non-null object
6   Населенный пункт                                                       256723 non-null object
7   Регион                                                                256723 non-null object
8   Численность населения                                                  256723 non-null int64
9   Количество домохозяйств                                                256723 non-null int64
10  Трафик пеший, в час                                                    256723 non-null float64
11  Трафик авто, в час                                                      256723 non-null float64
12  Маркетплейсы, доставки, постаматы (100 м)                             256723 non-null int64
13  Медицинские уч. и аптеки (300 м)                                       256723 non-null int64
14  Школы (300 м)                                                          256723 non-null int64
15  Остановки (300 м)                                                      256723 non-null int64
16  Продуктовые магазины (500 м)                                           256723 non-null int64
17  Пятерочки (500 м)                                                      256723 non-null int64
dtypes: float64(3), int64(11), object(4)
memory usage: 35.3+ MB
```

```
In [6]: df.isna().sum()
```

```
Out[6]: new_id          0
        Месяц          0
        Трафик         0
        Средний чек     0
        Дата открытия, категориальный  0
        Торговая площадь, категориальный  0
        Населенный пункт  0
        Регион         0
        Численность населения  0
        Количество домохозяйств  0
        Трафик пеший, в час  0
        Трафик авто, в час  0
        Маркетплейсы, доставки, постаматы (100 м)  0
        Медицинские уч. и аптеки (300 м)  0
        Школы (300 м)    0
        Остановки (300 м)  0
        Продуктовые магазины (500 м)  0
        Пятерочки (500 м)  0
        dtype: int64
```

```
In [7]: df['new_id'].nunique()
```

```
Out[7]: 21743
```

```
In [8]: df.duplicated().sum()
```

Out[8]: np.int64(0)

```
In [9]: df.duplicated(subset=['new_id', 'Месяц']).sum()
```

Out[9]: np.int64(12)

```
In [10]: df[df.duplicated(subset=['new_id', 'Месяц'], keep = False)]
```

Out[10]:

	new_id	Месяц	Трафик	Средний чек	Дата открытия, категориальный	Торгова площадь категориальный
165905	13842	9	56253	813.800294	Новый	Средни
165906	13842	5	55744	774.269056	Новый	Средни
165907	13842	11	55034	887.869896	Новый	Средни
165908	13842	12	56601	983.275476	Новый	Средни
165909	13842	4	56410	765.066865	Новый	Средни
165910	13842	1	50437	768.432619	Новый	Средни
165911	13842	7	56573	799.565330	Новый	Средни
165912	13842	8	57029	805.408329	Новый	Средни
165913	13842	10	57715	827.479989	Новый	Средни
165914	13842	6	55787	761.978286	Новый	Средни
165915	13842	2	51525	779.700762	Новый	Средни
165916	13842	3	56140	805.221557	Новый	Средни
165917	13842	9	56109	806.125587	Новый	Средни
165918	13842	5	56025	782.441090	Новый	Средни
165919	13842	11	55719	890.582544	Новый	Средни
165920	13842	12	57147	972.845868	Новый	Средни
165921	13842	4	56097	768.535225	Новый	Средни
165922	13842	1	50699	744.972820	Новый	Средни
165923	13842	7	56671	794.015810	Новый	Средни

	new_id	Месяц	Трафик	Средний чек	Дата открытия, категориальный	Торгова площадь категориальный
165924	13842	8	57210	806.184034	Новый	Средни
165925	13842	10	56821	845.037807	Новый	Средни
165926	13842	6	55563	769.725726	Новый	Средни
165927	13842	2	52282	761.327144	Новый	Средни
165928	13842	3	56454	807.491308	Новый	Средни

```
In [11]: df1 = df.groupby('new_id')['new_id'].value_counts().reset_index()
df1
```

```
Out[11]:
```

	new_id	count
0	0	12
1	1	12
2	2	12
3	3	12
4	4	12
...
21738	21738	5
21739	21739	5
21740	21740	6
21741	21741	6
21742	21742	5

21743 rows × 2 columns

```
In [12]: df1[df1['count'] < 12]
```

```
Out[12]:
```

	new_id	count
727	727	10
914	914	8
915	915	8
973	973	11
976	976	3
...
21738	21738	5
21739	21739	5
21740	21740	6
21741	21741	6
21742	21742	5

1107 rows × 2 columns

```
In [13]: df1[df1['count'] > 12]
```

```
Out[13]:
```

	new_id	count
13842	13842	24

```
In [14]: df = df.drop_duplicates(subset=['new_id', 'Месяц'], keep=False)
```

```
In [15]: df1 = df.groupby('new_id')['new_id'].value_counts().reset_index()
```

```
In [16]: df1[df1['count'] > 12]
```

```
Out[16]:
```

	new_id	count
--	--------	-------

```
In [20]: df2 = df[['new_id', 'Торговая площадь, категориальный', 'Населенный пункт', 'Регион', 'Численность населения']]
df2[(df2['Торговая площадь, категориальный'] > 1) | (df2['Населенный пункт'] > 1)]
```

```
Out[20]:
```

	new_id	Торговая площадь, категориальный	Населенный пункт	Регион	Численность населения
--	--------	-------------------------------------	---------------------	--------	--------------------------

```
In [21]: df.to_csv('path', encoding = 'cp1251')
```